

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN



TRÍCH XUẤT QUAN HỆ TƯƠNG TÁC
THUỐC (DDI)
SỬ DỤNG MÔ HÌNH HỌC SÂU SEG-GCRN

Mã học phần: MAT1204

Sinh viên thực hiện: 1. Nguyễn Hữu Duy - 23001853
2. Lô Văn Quỳnh - 22001282

Giảng viên hướng dẫn: Ngô Thế Quyền

HÀ NỘI – 2026

Thông tin Dự án

Mã học phần: MAT1204 9

Học kỳ: Học kỳ 2, Năm học 2026-2027

Trường: VNU-HUS (Đại học Quốc gia Hà Nội – Trường Đại học Khoa học Tự nhiên)

Tên dự án: Trích xuất quan hệ tương tác thuốc (DDI) sử dụng mô hình học sâu Seg-GCRN

Báo cáo PDF: <https://github.com/23001853-wq/graph-embedding-relation-extraction/blob/main/Baocao.pdf>

Slide thuyết trình: <https://github.com/23001853-wq/graph-embedding-relation-extraction/blob/main/Slide.pdf>

Kho GitHub: <https://github.com/23001853-wq/graph-embedding-relation-extraction>

Thành viên nhóm

Họ tên	Mã sinh viên	Tên GitHub
Nguyễn Hữu Duy	23001853	23001853-wq
Lô Văn Quỳnh	22001282	lovanquynh

LỜI CAM ĐOAN

Chúng tôi xin cam đoan các kết quả trình bày trong đồ án này là công trình nghiên cứu của nhóm sinh viên chúng tôi trong thời gian học tập tại Trường Đại học Khoa học Tự nhiên, Đại học Quốc gia Hà Nội, dưới sự hướng dẫn của giảng viên Ngô Thế Quyền. Các số liệu, kết quả trình bày trong đồ án là hoàn toàn trung thực. Các kết quả sử dụng tham khảo đều đã được trích dẫn đầy đủ và theo đúng quy định.

Hà Nội, ngày 27 tháng 5 năm 2026

Sinh viên thực hiện 1

Sinh viên thực hiện 2

Nguyễn Hữu Duy
MSV: 23001853

Lô Văn Quỳnh
MSV: 22001282

LỜI CẢM ƠN

Trong quá trình học tập, nghiên cứu và thực hiện đề án này, chúng tôi xin gửi lời cảm ơn chân thành và sâu sắc nhất tới giảng viên hướng dẫn của mình là thầy **Ngô Thế Quyền**. Thầy đã luôn nhiệt tình chỉ dạy, định hướng khoa học, chia sẻ và động viên nhóm rất nhiều trong suốt quá trình triển khai dự án. Chúng tôi luôn trân trọng, biết ơn và ghi nhớ khoảng thời gian quý báu được làm việc dưới sự hướng dẫn của thầy.

Đồng thời, chúng tôi cũng xin gửi lời cảm ơn đến các thầy cô trong Trường Đại học Khoa học Tự nhiên, Đại học Quốc gia Hà Nội đã trang bị cho chúng tôi những kiến thức nền tảng vững chắc để có thể hoàn thành tốt đề án này. Cuối cùng, xin gửi lời tri ân tới gia đình và bạn bè đã luôn đồng hành, ủng hộ chúng tôi trong suốt thời gian qua.

Hà Nội, ngày 25 tháng 5 năm 2026

MỤC LỤC

LỜI CAM ĐOAN	i
LỜI CẢM ƠN	ii
DANH MỤC TỪ VIẾT TẮT VÀ THUẬT NGỮ.....	v
MỞ ĐẦU	1
CHƯƠNG 1. TỔNG QUAN VÀ HIỆN TRẠNG NGHIÊN CỨU	3
1.1. Giới thiệu bài toán Tương tác thuốc (DDI)	3
1.2. Hạn chế của các phương pháp trích xuất trước đây.....	3
1.2.1. Phương pháp thủ công và dựa trên luật (Rule-based).....	3
1.2.2. Phương pháp học máy truyền thống và mạng chuỗi cơ bản.....	3
1.3. Giải pháp đề xuất: Mạng Seg-GCRN.....	4
1.3.1. Ý tưởng cốt lõi	4
1.3.2. Những điểm nổi bật của hệ thống.....	4
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ PHÂN TÍCH DỮ LIỆU	5
2.1. Cơ sở lý thuyết học sâu.....	5
2.1.1. Xử lý ngôn ngữ tự nhiên và Cú pháp phụ thuộc.....	5
2.1.2. Mạng chuỗi (Bi-LSTM) và Mạng đồ thị (GCN)	5
2.2. Phân tích dữ liệu hệ thống (Data Analysis)	5
2.2.1. Tập dữ liệu DDI 2013 Corpus.....	5
2.2.2. Cấu trúc XML và đặc trưng nhãn.....	6
2.2.3. Bài toán mất cân bằng dữ liệu (Imbalanced Data)	6
CHƯƠNG 3. THIẾT KẾ VÀ XÂY DỰNG HỆ THỐNG AI.....	7
3.1. Tổng quan kiến trúc hệ thống.....	7
3.2. Luồng xử lý dữ liệu (Data Pipeline).....	8
3.2.1. Phân tích cú pháp và bóc tách dữ liệu XML (XML Parsing & Structuring)	
8	
3.2.2. Làm sạch văn bản và tách từ (Text Cleansing & Tokenization) ..	8

3.2.3. Phân tích phụ thuộc cú pháp và xây dựng cấu trúc đồ thị (Dependency Parsing & Graph Construction)	9
3.2.4. Chuẩn hóa dữ liệu đầu vào và quản lý tập dữ liệu (Input Standardization & Data Management)	9
3.2.5. Cấu trúc biểu diễn dữ liệu cuối cùng (Final Input Representation) ..	10
3.3. Thiết kế mô hình Seg-GCRN	10
3.3.1. Khối biểu diễn đặc trưng (Embedding Layer)	11
3.3.2. Khối trích xuất ngữ cảnh (Sequence Encoder)	11
3.3.3. Khối trích xuất đồ thị (Graph Encoder)	11
3.3.4. Khối gộp phân đoạn (Segment Representation & Pooling)	12
3.3.5. Khối phân loại (Classifier)	12
CHƯƠNG 4. HUẤN LUYỆN, TRIỂN KHAI VÀ ĐÁNH GIÁ.	13
4.1. Môi trường và Công nghệ sử dụng	13
4.2. Huấn luyện và Tối ưu hóa hệ thống	13
4.2.1. Chiến lược chia dữ liệu (Stratified Split)	13
4.2.2. Tối ưu hóa mất cân bằng với Class Weights	13
4.2.3. Hiệu chuẩn tự tin với Temperature Scaling	13
4.2.4. Quá trình huấn luyện (Training Process)	14
4.3. Đánh giá hệ thống (Evaluation)	14
4.3.1. Các độ đo đánh giá	14
4.3.2. Kết quả thực nghiệm tổng thể	14
4.3.3. Phân tích Ma trận nhầm lẫn (Confusion Matrix)	15
4.3.4. Phân tích ca kiểm thử thực tế (Case Study Analysis)	16
CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	18
5.1. Kết quả đạt được	18
5.2. Hạn chế của hệ thống	18
5.3. Hướng phát triển tương lai	19
TÀI LIỆU THAM KHẢO	20

DANH MỤC TỪ VIẾT TẮT VÀ THUẬT NGỮ

Từ viết tắt	Tiếng Anh	Ý nghĩa (Tiếng Việt)
AI	Artificial Intelligence	Trí tuệ Nhân tạo
Bi-LSTM	Bidirectional Long Short-Term Memory	Mạng bộ nhớ ngắn hạn hai chiều
DDI	Drug-Drug Interaction	Tương tác thuốc
Epoch	-	Vòng lặp huấn luyện toàn bộ tập dữ liệu
GCN	Graph Convolutional Network	Mạng nơ-ron tích chập đồ thị
JSON	JavaScript Object Notation	Định dạng hoán đổi dữ liệu nhẹ
Logits	-	Giá trị điểm số thô trước khi qua hàm kích hoạt
NLP	Natural Language Processing	Xử lý Ngôn ngữ Tự nhiên
Seg-GCRN	Segment Graph Convolutional Relational Network	Mạng quan hệ tích chập đồ thị dựa trên phân đoạn
XML	eXtensible Markup Language	Ngôn ngữ đánh dấu mở rộng

MỞ ĐẦU

1. Bối cảnh và lý do chọn đề tài

Việc nghiên cứu và triển khai đề tài xuất phát từ những bối cảnh và yêu cầu cấp thiết sau:

- **Thực trạng y tế và rủi ro lâm sàng:** Trong nền y học hiện đại, việc sử dụng đồng thời nhiều loại thuốc để điều trị các bệnh lý phức tạp là điều không thể tránh khỏi. Tuy nhiên, điều này dẫn đến rủi ro nghiêm trọng về Tương tác thuốc (Drug-Drug Interaction - DDI). Theo các báo cáo y tế toàn cầu, các phản ứng có hại do tương tác thuốc là một trong những nguyên nhân hàng đầu gây ra các ca nhập viện ngoài ý muốn và tạo ra gánh nặng tài chính khổng lồ cho hệ thống y tế.
- **Thách thức từ sự bùng nổ dữ liệu y sinh:** Kỷ nguyên số mang lại kho tàng tri thức khổng lồ (như PubMed, MedLine) với hàng nghìn bài báo được xuất bản mỗi ngày. Mặc dù chứa đựng những cảnh báo DDI vô giá, phần lớn thông tin này tồn tại dưới dạng văn bản phi cấu trúc. Việc yêu cầu chuyên gia y tế đọc, trích xuất và cập nhật thủ công là một nhiệm vụ bất khả thi, tốn kém tài nguyên và cực kỳ dễ xảy ra sai sót.
- **Tiềm năng của Trí tuệ Nhân tạo (AI):** Đứng trước thách thức đó, ứng dụng AI, đặc biệt là Xử lý Ngôn ngữ Tự nhiên (NLP), để tự động hóa quá trình "đọc hiểu" văn bản y khoa trở thành xu hướng tất yếu. Một hệ thống trích xuất DDI tự động không chỉ giúp số hóa dữ liệu thô thành tri thức có cấu trúc, mà còn đóng vai trò như một "trợ lý ảo" đắc lực. Khi được tích hợp vào các Hệ thống hỗ trợ quyết định lâm sàng (CDSS), nó giúp bác sĩ phát hiện tức thời nguy cơ DDI khi kê đơn, bảo vệ an toàn tối đa cho bệnh nhân.

Xuất phát từ tính cấp thiết và giá trị thực tiễn to lớn đó, đề tài "**Trích xuất quan hệ Tương tác thuốc (DDI) sử dụng mô hình học sâu Seg-GCRN**" đã được lựa chọn để nghiên cứu và triển khai.

2. Mục tiêu và phạm vi nghiên cứu

- **Mục tiêu nghiên cứu:** Đề án hướng tới việc xây dựng và tối ưu hóa một hệ thống học sâu có khả năng đọc hiểu câu văn bệnh án và phân loại chính xác mối quan hệ giữa hai thực thể thuốc. Cụ thể, nghiên cứu áp dụng kiến trúc mạng phân đoạn **Seg-GCRN** (Segment Graph Convolutional Relational

Network), tận dụng sức mạnh phân tích cú pháp của mạng đồ thị (GCN) và khả năng học ngữ cảnh chuỗi (Bi-LSTM).

- **Phạm vi nghiên cứu:** Đề án tập trung giải quyết bài toán phân loại quan hệ và giới hạn việc huấn luyện, đánh giá mô hình trên tập dữ liệu chuẩn quốc tế DDI 2013 Corpus.

3. Bố cục của đề án

Ngoài phần Mở đầu, Phụ lục và Tài liệu tham khảo, nội dung chính của đề án được cấu trúc thành 5 chương như sau:

- **Chương 1: Tổng quan và Hiện trạng nghiên cứu.** Trình bày tổng quan về bài toán DDI, phân tích hạn chế của các phương pháp cũ và giới thiệu giải pháp mạng Seg-GCRN.
- **Chương 2: Cơ sở lý thuyết và Phân tích dữ liệu.** Hệ thống hóa kiến thức về NLP, GCN, Bi-LSTM và phân tích chuyên sâu đặc trưng của tập dữ liệu DDI 2013 Corpus.
- **Chương 3: Thiết kế và Xây dựng Hệ thống AI.** Phác thảo luồng xử lý dữ liệu (Data Pipeline), kỹ thuật chống rò rỉ và cấu trúc chi tiết của hai luồng mạng nơ-ron.
- **Chương 4: Huấn luyện, Triển khai và Đánh giá.** Trình bày cấu hình huấn luyện, các kỹ thuật tối ưu (Class Weights, Temperature Scaling) và kết quả thực nghiệm.
- **Chương 5: Kết luận và Hướng phát triển.** Đánh giá tổng thể hệ thống, chỉ ra hạn chế và đề xuất các định hướng nâng cấp trong tương lai.

Chương 1

TỔNG QUAN VÀ HIỆN TRẠNG NGHIÊN CỨU

1.1. Giới thiệu bài toán Tương tác thuốc (DDI)

Tương tác thuốc (Drug-Drug Interaction – DDI) là hiện tượng tác dụng dược lý của một thuốc bị thay đổi bởi sự hiện diện của thuốc khác khi được sử dụng đồng thời. Các tương tác này có thể làm tăng độc tính, làm giảm hiệu quả điều trị hoặc gây ra những phản ứng bất lợi nghiêm trọng cho bệnh nhân.

Trong khai phá văn bản y sinh, bài toán trích xuất DDI được định nghĩa là nhiệm vụ tự động nhận diện và phân loại mối quan hệ tương tác giữa các thực thể thuốc xuất hiện trong câu hoặc tài liệu y khoa. Đây là một bài toán quan trọng trong xử lý ngôn ngữ tự nhiên y sinh (Biomedical NLP), có ý nghĩa lớn trong việc xây dựng cơ sở tri thức phục vụ hệ thống hỗ trợ kê đơn lâm sàng..

1.2. Hạn chế của các phương pháp trích xuất trước đây

Trước sự phát triển của Trí tuệ Nhân tạo, việc trích xuất DDI đã trải qua nhiều giai đoạn với các phương pháp tiếp cận khác nhau, nhưng vẫn tồn tại nhiều điểm nghẽn lớn.

1.2.1. Phương pháp thủ công và dựa trên luật (Rule-based)

Phương pháp trích xuất thủ công đòi hỏi chuyên gia y tế phải tự đọc và ghi nhận dữ liệu. Cách làm này tốn kém tài nguyên, tốc độ chậm và không thể bắt kịp lượng tài liệu khổng lồ. Để cải thiện, các hệ thống dựa trên luật (Rule-based) ra đời, sử dụng các từ điển y khoa và các mẫu cú pháp cố định (ví dụ: "Thuốc A làm tăng tác dụng của Thuốc B"). Tuy nhiên, ngôn ngữ tự nhiên cực kỳ đa dạng, việc phụ thuộc vào bộ luật cứng nhắc khiến hệ thống dễ bị đánh lừa bởi các câu phức, câu phủ định kép và chi phí bảo trì bộ luật là rất đắt đỏ.

1.2.2. Phương pháp học máy truyền thống và mạng chuỗi cơ bản

Các mô hình học máy truyền thống (như SVM) phụ thuộc rất nhiều vào quá trình trích xuất đặc trưng thủ công (Feature Engineering). Trong khi đó, các mạng nơ-ron chuỗi cơ bản (như RNN hay LSTM đơn thuần) lại gặp hạn chế nghiêm trọng về "ngữ cảnh tầm xa". Khi hai thực thể thuốc nằm cách quá xa

nhau trong một câu bệnh án dài, các mạng này có xu hướng quên mất thông tin liên kết ngữ pháp giữa chúng, dẫn đến việc bỏ lọt (False Negative) các tương tác quan trọng.

1.3. Giải pháp đề xuất: Mạng Seg-GCRN

Để khắc phục triệt để các hạn chế trên, đề án đề xuất xây dựng hệ thống tự động trích xuất DDI dựa trên kiến trúc học sâu **Seg-GCRN** (Segment Graph Convolutional Relational Network).

1.3.1. Ý tưởng cốt lõi

Hệ thống kết hợp sức mạnh của hai luồng xử lý: Mạng bộ nhớ ngắn hạn hai chiều (Bi-LSTM) để nắm bắt ngữ cảnh theo chuỗi thời gian, và Mạng tích chập đồ thị (GCN) hoạt động trên đồ thị phụ thuộc cú pháp. GCN đóng vai trò như một "đường tắt", rút ngắn khoảng cách giữa các từ vựng có liên kết ngữ pháp dù chúng nằm ở hai đầu của câu văn, giúp mô hình hiểu được bản chất mối quan hệ một cách sâu sắc.

1.3.2. Những điểm nổi bật của hệ thống

Giải pháp không chỉ dừng lại ở mặt kiến trúc mạng, mà còn giải quyết các bài toán thực tiễn của một kỹ sư dữ liệu:

- **Bảo toàn dữ liệu:** Khắc phục hiện tượng rò rỉ dữ liệu (Data Leakage) bằng kỹ thuật tịnh tiến vị trí (Position Shift) và ép giới hạn (Clamp) ngay tại khâu tải dữ liệu.
- **Tối ưu mất cân bằng:** Xử lý tình trạng nhãn DDI cực hiếm trong thực tế bằng bộ trọng số lớp (Class Weights), ép AI ưu tiên chỉ số bao phủ (Recall).
- **Hiệu chuẩn tự tin:** Áp dụng kỹ thuật Temperature Scaling tại khâu suy luận, giúp điểm số dự đoán của mô hình khiêm tốn và đáng tin cậy hơn đối với bác sĩ.

Chương 2

CƠ SỞ LÝ THUYẾT VÀ PHÂN TÍCH DỮ LIỆU

Chương này trình bày các khái niệm nền tảng về thuật toán học sâu và tiến hành phân tích chuyên sâu bộ dữ liệu y khoa được sử dụng làm đầu vào cho toàn bộ hệ thống.

2.1. Cơ sở lý thuyết học sâu

2.1.1. Xử lý ngôn ngữ tự nhiên và Cú pháp phụ thuộc

Xử lý ngôn ngữ tự nhiên (NLP) là cầu nối giúp máy tính hiểu được văn bản của con người. Trong y khoa, thay vì đọc câu theo dạng chuỗi tuyến tính, hệ thống sử dụng **Phân tích cú pháp phụ thuộc (Dependency Parsing)** để tìm ra mối quan hệ bổ nghĩa giữa các từ (Chủ ngữ - Vị ngữ - Bổ ngữ). Kết quả trả về là một đồ thị có hướng, được số hóa dưới dạng Ma trận kề (Adjacency Matrix) để mô hình học sâu có thể tính toán.

2.1.2. Mạng chuỗi (Bi-LSTM) và Mạng đồ thị (GCN)

- **Bi-LSTM:** Là bản nâng cấp của LSTM, đọc chuỗi văn bản đồng thời từ trái sang phải và từ phải sang trái. Nó giúp lưu giữ ngữ cảnh tuyến tính cục bộ xung quanh thực thể thuốc.
- **GCN:** Mạng nơ-ron tích chập đồ thị (Graph Convolutional Network) thực hiện lan truyền thông tin qua các cạnh của đồ thị cú pháp. Từ vựng sẽ cập nhật trạng thái của mình bằng cách tổng hợp đặc trưng từ các từ lân cận trong sơ đồ ngữ pháp, bỏ qua khoảng cách vật lý của chúng trong câu.

2.2. Phân tích dữ liệu hệ thống (Data Analysis)

Việc thấu hiểu bản chất của bộ dữ liệu là bước quan trọng nhất quyết định sự thành bại của mô hình học máy.

2.2.1. Tập dữ liệu DDI 2013 Corpus

Đề án sử dụng bộ dữ liệu chuẩn quốc tế DDI Extraction 2013 Corpus. Đây là bộ Benchmark kinh điển được thu thập từ các cơ sở dữ liệu y khoa uy tín như

DrugBank và MedLine, chuyên dùng để đánh giá các mô hình học sâu toàn cầu.

2.2.2. Cấu trúc XML và đặc trưng nhãn

Dữ liệu thô gốc được cung cấp dưới định dạng XML. Mỗi văn bản chứa nhiều câu phức tạp, bên trong đánh dấu vị trí chính xác (character offset) của các thực thể thuốc bằng các thẻ <entity>. Các cặp thuốc trong cùng một câu được liên kết bằng thẻ <pair>, đi kèm với nhãn ddi="true" (có tương tác) hoặc ddi="false" (không có tương tác).

2.2.3. Bài toán mất cân bằng dữ liệu (Imbalanced Data)

Qua quá trình bóc tách và phân tích thống kê (Exploratory Data Analysis), hệ thống ghi nhận một thách thức cực kỳ lớn: Sự mất cân bằng nhãn trầm trọng. Trong y tế lâm sàng, phần lớn các loại thuốc khi uống cùng nhau không gây ra phản ứng. Điều này phản ánh trực tiếp vào tập dữ liệu khi nhãn FALSE chiếm tới gần 90% tổng số mẫu, trong khi nhãn TRUE chỉ chiếm khoảng 10%.

Nếu không có biện pháp can thiệp, mô hình sẽ nảy sinh xu hướng "lười biếng", liên tục đoán FALSE để đạt độ chính xác (Accuracy) 90% một cách dễ dàng, nhưng lại hoàn toàn vô dụng trong thực tế vì bỏ lọt mọi ca tương tác nguy hiểm. Thách thức này đặt ra yêu cầu bắt buộc phải thiết kế lại hàm mất mát trong Chương 3.

Bảng 2.1: Thống kê phân phối nhãn trong các tập dữ liệu thực nghiệm

Tập dữ liệu	Tổng số cặp	Nhãn TRUE (DDI)	Nhãn FALSE (Không tương tác)	Tỷ lệ F/T
Train (80%)	19.745	2.021 (10,2%)	17.724 (89,8%)	8,77
Validation (20%)	4.937	505 (10,2%)	4.432 (89,8%)	8,78
Test (Unseen)	6.171	631 (10,2%)	5.540 (89,8%)	8,78
Tổng cộng	30.853	3.157	27.696	-


Chương 3

THIẾT KẾ VÀ XÂY DỰNG HỆ THỐNG AI

Chương này trình bày chi tiết về kiến trúc tổng thể của hệ thống, từ bước thiết kế luồng xử lý dữ liệu (Data Pipeline) chống rò rỉ, cho đến cấu trúc bên trong của mô hình học sâu Seg-GCRN.

3.1. Tổng quan kiến trúc hệ thống

Để giải quyết bài toán trích xuất tương tác thuốc (DDI), hệ thống được thiết kế theo một luồng xử lý (Pipeline) tuần tự, đi từ dữ liệu thô cho đến nhận dự đoán cuối cùng.



Hình 3.1: Sơ đồ luồng xử lý và kiến trúc tổng quan của hệ thống Seg-GCRN

Như được thể hiện trên sơ đồ, hệ thống bao gồm hai pha chính: Pha Tiền xử lý (từ XML Corpus đến Token Embedding) để chuẩn hóa văn bản thành

ma trận toán học, và Pha Trích xuất đặc trưng sử dụng hai luồng mạng nơ-ron song song (Bi-LSTM và GCN) trước khi đi qua lớp phân loại (Classifier) để đưa ra dự đoán (Prediction). Hệ thống trích xuất tương tác thuốc được thiết kế theo mô hình đường ống (Pipeline) bao gồm hai pha chính: Pha Tiền xử lý (Preprocessing Phase) để chuẩn hóa văn bản thành ma trận toán học, và Pha Trích xuất đặc trưng (Feature Extraction Phase) sử dụng mạng nơ-ron để dự đoán nhãn DDI.

3.2. Luồng xử lý dữ liệu (Data Pipeline)

Để dữ liệu đầu vào có thể được sử dụng cho bài toán trích xuất tương tác thuốc, bộ dữ liệu DDI 2013 Corpus cần trải qua một chuỗi bước tiền xử lý và chuẩn hóa trước khi đưa vào mô hình học sâu. Quy trình này nhằm chuyển đổi dữ liệu XML thô sang dạng có cấu trúc, đồng thời trích xuất các đặc trưng ngôn ngữ và thông tin vị trí cần thiết phục vụ huấn luyện. Toàn bộ luồng xử lý dữ liệu trong nghiên cứu gồm các bước chính như sau:

3.2.1. Phân tích cú pháp và bóc tách dữ liệu XML (XML Parsing & Structuring)

Bộ dữ liệu DDI 2013 được cung cấp dưới định dạng XML, trong đó mỗi tệp chứa nhiều câu cùng các thực thể thuốc và mối quan hệ giữa chúng. Ở bước đầu tiên, hệ thống thực hiện phân tích cú pháp XML để truy xuất nội dung câu, các thực thể thuốc được đánh dấu bởi thẻ `<entity>`, cùng các cặp quan hệ tương ứng trong thẻ `<pair>`.

Từ mỗi câu, hệ thống xác định vị trí xuất hiện của các thực thể dựa trên thông tin *character offsets*, sau đó ánh xạ từng cặp thuốc với nhãn quan hệ tương ứng. Những mẫu dữ liệu không hợp lệ, thiếu thực thể hoặc sai định dạng được loại bỏ trong giai đoạn này nhằm đảm bảo tính nhất quán của tập dữ liệu đầu vào.

3.2.2. Làm sạch văn bản và tách từ (Text Cleansing & Tokenization)

Sau khi trích xuất nội dung từ XML, văn bản tiếp tục được chuẩn hóa nhằm giảm nhiễu và đưa về định dạng phù hợp cho xử lý ngôn ngữ tự nhiên. Các ký tự không cần thiết được loại bỏ hoặc chuẩn hóa, đồng thời giữ nguyên các thành phần quan trọng như tên thuốc, thuật ngữ y sinh và dấu câu có giá trị nghĩa.

Tiếp theo, hệ thống sử dụng thư viện SpaCy để thực hiện tách từ (Tokenization). Mỗi câu được phân chia thành chuỗi token theo ngữ cảnh ngôn ngữ thay vì cắt đơn thuần theo khoảng trắng. Kết quả của bước này là biểu diễn tuần tự của câu dưới dạng danh sách token, phục vụ cho các bước xử lý tiếp theo.

3.2.3. Phân tích phụ thuộc cú pháp và xây dựng cấu trúc đồ thị (Dependency Parsing & Graph Construction)

Nhằm khai thác mối quan hệ ngữ pháp giữa các từ trong câu, hệ thống tiếp tục thực hiện phân tích phụ thuộc cú pháp (Dependency Parsing). Với mỗi câu, bộ phân tích sẽ xác định quan hệ phụ thuộc giữa các token như chủ ngữ, bổ nghĩa hoặc liên kết ngữ pháp.

Từ kết quả này, một ma trận kề (Adjacency Matrix) A được xây dựng để biểu diễn cấu trúc liên kết giữa các token trong câu. Cụ thể, phần tử A_{ij} của ma trận được xác định bởi công thức:

$$A_{ij} = \begin{cases} 1, & \text{nếu token } i \text{ có quan hệ phụ thuộc ngữ pháp với token } j \\ 0, & \text{trong các trường hợp còn lại} \end{cases} \quad (3.1)$$

Ma trận này đóng vai trò như biểu diễn đồ thị của câu, trong đó mỗi token được xem như một nút và quan hệ phụ thuộc giữa các token được biểu diễn dưới dạng cạnh kết nối.

3.2.4. Chuẩn hóa dữ liệu đầu vào và quản lý tập dữ liệu (Input Standardization & Data Management)

Ở bước cuối cùng, dữ liệu được chuẩn hóa để đảm bảo có thể đưa vào mô hình dưới dạng tensor. Đối với thông tin vị trí tương đối của token so với thực thể thuộc, hệ thống áp dụng kỹ thuật dịch chuyển giá trị (*Position Shift*) nhằm loại bỏ giá trị âm, sau đó giới hạn về một khoảng cố định bằng phép *Clamp*. Quá trình tiền xử lý vị trí này được biểu diễn qua công thức:

$$p'_i = \min(\max(p_i + k, 1), M) \quad (3.2)$$

Trong đó:

- p_i : là vị trí tương đối ban đầu của token i so với thực thể thuộc.
- k : là hệ số dịch chuyển (tịnh tiến) để chuyển đổi sang không gian số dương (trong hệ thống áp dụng $k = 120$).
- M : là giá trị giới hạn trên của mảng vị trí (trong hệ thống áp dụng $M = 249$).
- p'_i : là giá trị vị trí sau khi đã được chuẩn hóa để đưa vào mạng học sâu.

Việc này giúp đồng nhất miền giá trị đầu vào, loại bỏ độ nhiễu từ các câu bệnh án quá dài và hạn chế sai lệch trong quá trình cập nhật trọng số.

Sau khi hoàn tất tiền xử lý, tập dữ liệu được chia thành các tập huấn luyện, xác thực và kiểm thử theo phương pháp phân tầng (*Stratified Split*) dựa trên phân phối nhãn. Cách chia này giúp duy trì tỷ lệ nhãn giữa các tập dữ liệu, đồng thời đảm bảo tập kiểm thử được tách biệt hoàn toàn khỏi quá trình huấn luyện để phục vụ đánh giá mô hình một cách khách quan.

3.2.5. Cấu trúc biểu diễn dữ liệu cuối cùng (Final Input Representation)

Sau khi trải qua các bước tiền xử lý nghiêm ngặt, mỗi câu bệnh án được đóng gói thành một cấu trúc dữ liệu chuẩn hóa (Dictionary/JSON) trước khi chuyển đổi thành Tensor cho thư viện PyTorch. Một mẫu dữ liệu đầu vào hoàn chỉnh có dạng như sau:

```
{
  "token_ids": [396, 88, 669, 29, 232, 15, 387, 24, ...],
  "attention_mask": [1, 1, 1, 1, 1, 1, 1, 1, ...],
  "h_pos": {"text": "NORVASC", "token_start": 6, "token_end": 6},
  "t_pos": {"text": "warfarin", "token_start": 8, "token_end": 8},
  "pos1": [-6, -5, -4, -3, -2, -1, 0, 1, 2, ...],
  "pos2": [-8, -7, -6, -5, -4, -3, -2, -1, 0, ...],
  "segments": [1, 1, 1, 1, 1, 1, 2, 3, 4, 5, 5, 5, ...],
  "adj_matrix": [...]
```

Trong cấu trúc trên, hai mảng đặc trưng cốt lõi giúp định hướng mô hình bao gồm:

1. Mảng vị trí tương đối (Relative Position - pos1, pos2):

Được tính bằng khoảng cách từ vị trí hiện tại của token i đến vị trí của hai thực thể thuốc (Head và Tail). Công thức tổng quát trước khi dịch chuyển (Shift):

$$pos1_i = i - h_{start} \quad ; \quad pos2_i = i - t_{start} \quad (3.3)$$

2. Mảng phân đoạn ngữ cảnh (Context Segments):

Đây là đặc trưng quan trọng nhất của kiến trúc **Seg-GCRN**. Để giúp mô hình nhận biết cấu trúc của câu khi có sự xuất hiện của hai loại thuốc, câu văn được chia thành 5 phân đoạn (segments) rời rạc. Gọi E_1 và E_2 lần lượt là thực thể thuốc xuất hiện trước và xuất hiện sau trong câu. Giá trị phân đoạn s_i của token thứ i được định nghĩa bằng hàm toán học:

$$s_i = \begin{cases} 1, & \text{nếu } i < E_{1.start} \text{ (Đoạn trước thuốc 1)} \\ 2, & \text{nếu } E_{1.start} \leq i \leq E_{1.end} \text{ (Thực thể thuốc 1)} \\ 3, & \text{nếu } E_{1.end} < i < E_{2.start} \text{ (Đoạn giữa 2 thuốc)} \\ 4, & \text{nếu } E_{2.start} \leq i \leq E_{2.end} \text{ (Thực thể thuốc 2)} \\ 5, & \text{nếu } i > E_{2.end} \text{ (Đoạn sau thuốc 2)} \end{cases} \quad (3.4)$$

Mảng *segments* này sau đó sẽ được đưa qua một lớp nhúng (Embedding Layer) riêng biệt, cung cấp cho mạng nơ-ron nhận thức rõ ràng về không gian và ngữ cảnh xung quanh các cặp tương tác.

3.3. Thiết kế mô hình Seg-GCRN

Mô hình Seg-GCRN (Segment Graph Convolutional Relational Network) được thiết kế với nhiều luồng trích xuất thông tin song song nhằm tận dụng tối đa

đặc trưng cú pháp và ngữ cảnh của câu. Kiến trúc chi tiết được chia thành 5 khối chính như sau:

3.3.1. Khối biểu diễn đặc trưng (Embedding Layer)

Trước khi đưa vào mạng học sâu, các giá trị nguyên rời rạc từ dữ liệu đầu vào phải được chuyển đổi thành các vector liên tục. Lớp biểu diễn của hệ thống là sự kết hợp (Concatenation) của 4 loại Embedding:

- **Word Embedding:** Vector ngữ nghĩa của từ vựng.
- **Position Embeddings (P_1, P_2):** Vector biểu diễn khoảng cách tương đối từ token hiện tại đến hai thực thể thuộc.
- **Segment Embedding:** Vector biểu diễn phân đoạn (1 đến 5) để định vị cấu trúc không gian của câu.

Vectơ đầu vào x_i của token thứ i được tổng hợp theo công thức:

$$x_i = [E_{word}(w_i) \oplus E_{pos}(p1_i) \oplus E_{pos}(p2_i) \oplus E_{seg}(s_i)] \quad (3.5)$$

Trong đó $\oplus$ là phép toán ghép nối vector.

3.3.2. Khối trích xuất ngữ cảnh (Sequence Encoder)

Khối này sử dụng kiến trúc Mạng bộ nhớ ngắn hạn hai chiều (Bi-LSTM). Nó tiếp nhận chuỗi vector $X = (x_1, x_2, \dots, x_n)$ và đọc đồng thời theo hai hướng. Trạng thái ẩn h_i tại bước thời gian i giúp nắm bắt các tín hiệu ngữ nghĩa tuyến tính cục bộ xung quanh hai thực thể thuộc:

$$h_i = [\overrightarrow{LSTM}(x_i) \oplus \overleftarrow{LSTM}(x_i)] \quad (3.6)$$

3.3.3. Khối trích xuất đồ thị (Graph Encoder)

Để khắc phục nhược điểm "mất kết nối tầm xa" của mạng chuỗi, hệ thống áp dụng Mạng tích chập đồ thị (GCN) trực tiếp lên ma trận kề cú pháp A . Để quá trình huấn luyện ổn định, ma trận kề trước hết được chuẩn hóa bằng cách thêm vòng lặp tự thân (Self-loop) và chuẩn hóa qua ma trận bậc (Degree Matrix) D :

$$\hat{A} = D^{-1/2}(A + I)D^{-1/2} \quad (3.7)$$

Trong đó, I là ma trận đơn vị. Quá trình lan truyền ở lớp GCN thứ l được định nghĩa bằng:

$$H^{(l+1)} = ReLU(\hat{A}H^{(l)}W^{(l)} + b^{(l)}) \quad (3.8)$$

Trong đó $H^{(l)}$ là ma trận trạng thái ẩn, $W^{(l)}$ là ma trận trọng số và $b^{(l)}$ là độ lệch của lớp đồ thị.

3.3.4. Khối gộp phân đoạn (Segment Representation & Pooling)

Đầu ra của Bi-LSTM và GCN vẫn là ma trận biểu diễn ở mức token. Tuy nhiên, nhiệm vụ của bài toán là dự đoán quan hệ ở mức câu giữa hai thực thể thuốc. Vì vậy, mô hình cần chuyển đổi các biểu diễn token này thành một vector đặc trưng toàn cục.

Dựa trên thông tin mảng **segments** đã được gán trong giai đoạn tiền xử lý, câu được chia thành 5 phân đoạn theo vị trí tương đối với hai thực thể thuốc: trước thực thể thứ nhất, thực thể thứ nhất, vùng giữa hai thực thể, thực thể thứ hai và phần sau thực thể thứ hai.

Trên mỗi phân đoạn, mô hình áp dụng phép Max-Pooling để trích xuất đặc trưng nổi bật nhất. Các vector đặc trưng này sau đó được ghép nối để tạo thành vector biểu diễn toàn cục:

$$v_{final} = v_1 \oplus v_2 \oplus v_3 \oplus v_4 \oplus v_5 \quad (3.9)$$

Trong đó v_i là vector đại diện của phân đoạn thứ i , giúp mô hình giữ lại nguyên vẹn cả thông tin ngữ cảnh xung quanh lẫn mối quan hệ giữa hai thực thể.

3.3.5. Khối phân loại (Classifier)

Vector biểu diễn toàn cục v_{final} được đưa qua lớp kết nối đầy đủ (Fully Connected Layer) để ánh xạ sang không gian nhẵn. Sau đó, hàm Softmax được sử dụng để tính xác suất thuộc mỗi lớp:

$$\hat{y} = \text{Softmax}(W_c \cdot v_{final} + b_c) \quad (3.10)$$

Trong đó W_c là ma trận trọng số và b_c là vector bias của tầng phân loại. Đầu ra cuối cùng của mô hình là phân phối xác suất trên hai lớp bài toán:

- **Interaction (DDI = TRUE):** Có tương tác thuốc.
- **Non-Interaction (DDI = FALSE):** Không có tương tác thuốc.

Toàn bộ mạng được huấn luyện end-to-end bằng cách tối ưu hóa hàm mất mát Cross-Entropy.

Chương 4

HUẤN LUYỆN, TRIỂN KHAI VÀ ĐÁNH GIÁ

4.1. Môi trường và Công nghệ sử dụng

Hệ thống được phát triển hoàn toàn trên ngôn ngữ Python, sử dụng khung học sâu mã nguồn mở PyTorch để tận dụng khả năng tính toán song song trên GPU. Các siêu tham số (Hyperparameters) được thiết lập cho quá trình huấn luyện bao gồm: Kích thước lô (Batch Size) là 32, Tốc độ học (Learning Rate) là 0.0005, và Hệ số suy giảm trọng số (Weight Decay) là 10^{-5} nhằm hạn chế Overfitting.

4.2. Huấn luyện và Tối ưu hóa hệ thống

4.2.1. Chiến lược chia dữ liệu (Stratified Split)

Để đảm bảo tính khách quan, dữ liệu được chia theo tỷ lệ 80% (Huấn luyện) - 20% (Xác thực - Validation). Đặc biệt, hệ thống duy trì một Tập kiểm thử (Unseen Test Set) được tách biệt hoàn toàn khỏi quá trình huấn luyện và chỉ sử dụng một lần ở giai đoạn đánh giá cuối cùng để xuất điểm báo cáo.

4.2.2. Tối ưu hóa mất cân bằng với Class Weights

Đối mặt với việc nhân TRUE (có tương tác) chỉ chiếm khoảng 10% dữ liệu, hệ thống đã can thiệp trực tiếp vào hàm mất mát Cross-Entropy. Bằng cách gán bộ trọng số phạt [1.0, 6.3], mô hình bị "phạt" nặng gấp 6.3 lần nếu dự đoán sai một ca có tương tác, từ đó ép AI tập trung vào việc bảo vệ bệnh nhân thay vì chạy theo bề nổi của độ chính xác tổng thể.

4.2.3. Hiệu chuẩn tự tin với Temperature Scaling

Mạng nơ-ron thường mắc phải hiện tượng "tự tin thái quá" (Overconfidence) khi sử dụng hàm Softmax. Đồ án áp dụng kỹ thuật Temperature Scaling tại bước suy luận (Inference), trong đó điểm số thô z_i được chia cho hằng số nhiệt độ $T = 4.0$ trước khi tính xác suất q_i :

$$q_i = \frac{\exp(z_i/T)}{\sum_j \exp(z_j/T)} \quad (4.1)$$

Kỹ thuật này giúp phân phối xác suất trở nên "mềm" hơn, cung cấp cho bác sĩ một hệ số tin cậy thực tế và khiêm tốn.

4.2.4. Quá trình huấn luyện (Training Process)

Mô hình Seg-GCRN được huấn luyện trong 30 vòng (Epochs) với thuật toán tối ưu Adam. Tại mỗi epoch, hệ thống liên tục giám sát hiệu suất trên tập Validation. Trọng số của mô hình (Best Checkpoint) chỉ được lưu lại khi đạt chỉ số F1-Score hoặc Recall tốt nhất trên tập Validation. Cơ chế này đảm bảo mô hình giữ được trạng thái tổng quát hóa cao nhất, tránh hiện tượng học vẹt (Overfitting) khi huấn luyện quá lâu trên tập Train.

4.3. Đánh giá hệ thống (Evaluation)

4.3.1. Các độ đo đánh giá

Do dữ liệu mất cân bằng trầm trọng, hệ thống không sử dụng Accuracy làm thước đo chính, mà tập trung đánh giá qua 3 chỉ số cốt lõi: Precision (Độ chuẩn xác), Recall (Độ bao phủ) và F1-Score (Trung bình điều hòa). Trong lĩnh vực y tế, Recall là chỉ số sống còn để tránh bỏ sót tương tác thuốc nguy hiểm.

4.3.2. Kết quả thực nghiệm tổng thể

Đánh giá độ ổn định của mô hình trên các tập dữ liệu chưa từng gặp là bước quan trọng để xác định năng lực thực tế của AI.

BÁO CÁO HIỆU SUẤT TỔNG THỂ (BEST CHECKPOINT SEG-GCRN)			
Chỉ số (Metrics)	Validation Set		Test Set (Unseen)
Accuracy	91.61%		91.35%
Precision	56.72%		55.24%
Recall	76.04%		80.98%
F1-Score	64.97%		65.68%
Model học tốt không học vẹt sự chênh lệch các chỉ số không đáng kể			


Hình 4.1: Báo cáo hiệu suất tổng thể trên tập Validation và Test

Kết quả cho thấy sự chênh lệch chỉ số giữa tập Validation và tập Test là cực kỳ nhỏ (Accuracy duy trì ở mức > 91%, F1-Score dao động quanh 64% - 65%). Đặc biệt, chỉ số Recall trên tập Test đạt mức ấn tượng 80.98%, thậm chí còn

nhỉnh hơn tập Validation. Sự đồng đều này là minh chứng rõ ràng cho thấy mô hình Seg-GCRN có khả năng tổng quát hóa tốt, thực sự học được quy luật cú pháp và ngữ nghĩa từ dữ liệu, hoàn toàn không xảy ra hiện tượng học vẹt (Overfitting).

4.3.3. Phân tích Ma trận nhầm lẫn (Confusion Matrix)

Để có cái nhìn sâu sắc hơn về hành vi dự đoán của hệ thống đối với từng nhãn, đồ án tiến hành trích xuất Ma trận nhầm lẫn trên tập Test



Hình 4.2: Ma trận nhầm lẫn (Confusion Matrix) trên tập Test

Nhìn vào ma trận, ta thấy rõ tác động mạnh mẽ và đúng đắn của chiến lược sử dụng trọng số lớp (Class Weights [1.0, 6.3]) đã thiết lập và đối với những câu từ khó sẽ dễ bị nhầm lẫn một ít:

- **True Positives (511) và False Negatives (120):** Mô hình nhận diện thành công 511 ca có tương tác thực sự và chỉ bỏ sót 120 ca (False Negatives). Tỷ lệ bỏ sót cực kỳ thấp này đáp ứng hoàn hảo yêu cầu khắt khe của hệ thống y tế — ưu tiên bắt nhầm còn hơn bỏ sót.
- **True Negatives (5126) và False Positives (414):** Mô hình nhận diện chính xác tuyệt đại đa số các ca an toàn. Đổi lại việc đẩy Recall lên cao, hệ thống chấp nhận đánh đổi một lượng nhỏ False Positives (414 ca bị cảnh báo "oan"). Trong thực tế lâm sàng, sự đánh đổi này là hoàn toàn có chủ đích và hợp lý: bác sĩ có thể dễ dàng kiểm tra và bỏ qua một cảnh báo

nhầm, nhưng bệnh nhân có thể gặp nguy hiểm tính mạng nếu một tương tác thuốc bị AI bỏ lọt. Mặc dù vậy, kết quả này cũng phản ánh rằng mô hình vẫn có thể xảy ra nhầm lẫn đối với một số ngữ cảnh hoặc cấu trúc câu biểu đạt quá phức tạp.

4.3.4. Phân tích ca kiểm thử thực tế (Case Study Analysis)

Để minh họa trực quan năng lực suy luận ngữ nghĩa của mô hình Seg-GCRN sau khi được hiệu chuẩn nhiệt độ ($T = 4.0$), đồ án lựa chọn 5 trường hợp tiêu biểu nhằm thể hiện khả năng xử lý các dạng ngữ cảnh y khoa phức tạp.

- **Ca 1: Nhận diện cơ chế dược lý (Mechanism)**

- *Câu bệnh án:* 'ketoconazole increased the plasma concentration of cyclosporine by inhibiting CYP3A4 metabolism.'
- *Cặp thực thể:* ketoconazole | cyclosporine
- *Hệ thống dự đoán:* **CÓ TƯƠNG TÁC (TRUE)** | Độ tự tin: 78.6% | Thời gian: 1.00 ms
- *Nhận xét:* Mô hình nắm bắt chính xác từ khóa "inhibiting CYP3A4", hiểu được cơ chế ức chế enzyme làm tăng nồng độ thuốc trong máu.

- **Ca 2: Phân tích hiệu ứng lâm sàng (Effect)**

- *Câu bệnh án:* 'Co-administration of warfarin and aspirin significantly increased the risk of bleeding.'
- *Cặp thực thể:* warfarin | aspirin
- *Hệ thống dự đoán:* **CÓ TƯƠNG TÁC (TRUE)** | Độ tự tin: 72.7% | Thời gian: 1.96 ms
- *Nhận xét:* Hệ thống nhận diện thành công hậu quả lâm sàng ("increased the risk of bleeding") khi sử dụng chung hai loại thuốc.

- **Ca 3: Trích xuất khuyến cáo y tế (Advice)**

- *Câu bệnh án:* 'The concomitant use of bumetanide with aminoglycoside antibiotics should be avoided, except in life-threatening situations.'
- *Cặp thực thể:* bumetanide | aminoglycoside antibiotics
- *Hệ thống dự đoán:* **CÓ TƯƠNG TÁC (TRUE)** | Độ tự tin: 95.0% | Thời gian: 2.00 ms
- *Nhận xét:* Phản ứng rất nhạy với các cụm từ mang tính cảnh báo mức độ cao ("should be avoided").

- **Ca 4: Xử lý cấu trúc phủ định (Negation)**

- *Câu bệnh án:* 'No clinically significant interaction was observed between aspirin and metformin.'
- *Cặp thực thể:* aspirin | metformin
- *Hệ thống dự đoán:* **KHÔNG TƯƠNG TÁC (FALSE)** | Độ tự tin: 100.0% | Thời gian: 3.00 ms
- *Nhận xét:* AI không bị đánh lừa bởi sự xuất hiện của từ "interaction", nhờ mạng GCN kết nối trực tiếp từ "interaction" với từ phủ định "No" đứng ở đầu câu.

• **Ca 5: Phân biệt đồng xuất hiện và tương tác (Co-occurrence)**

- *Câu bệnh án:* 'The patient was prescribed ibuprofen to relieve headaches and amoxicillin to relieve nausea.'
- *Cặp thực thể:* ibuprofen | amoxicillin
- *Hệ thống dự đoán:* **KHÔNG TƯƠNG TÁC (FALSE)** | Độ tự tin: 99.7% | Thời gian: 2.49 ms
- *Nhận xét:* Dù hai thuốc nằm trong cùng một câu, hệ thống phân tích cú pháp thành công việc mỗi thuốc phục vụ một mục đích độc lập ("relieve headaches" và "relieve nausea"), khẳng định mô hình không hề học vẹt theo khoảng cách từ vựng.

Chương 5

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1. Kết quả đạt được

Sau thời gian nghiên cứu và thực nghiệm nghiêm túc, đề án đã hoàn thành mục tiêu thiết kế và xây dựng thành công hệ thống tự động trích xuất quan hệ tương tác thuốc (DDI) từ văn bản y khoa. Những đóng góp và thành tựu nổi bật của hệ thống bao gồm:

- **Xây dựng luồng dữ liệu chuẩn xác:** Cài đặt thành công toàn bộ luồng xử lý (Pipeline) từ bước bóc tách dữ liệu XML, làm sạch văn bản, cho đến chuẩn hóa ma trận kề và chống rò rỉ dữ liệu bằng kỹ thuật tịnh tiến vị trí (*Position Shift & Clamp*).
- **Cài đặt thành công kiến trúc Seg-GCRN:** Tích hợp hiệu quả sức mạnh của mạng đồ thị cú pháp (GCN) để rút ngắn khoảng cách ngữ nghĩa và mạng chuỗi (Bi-LSTM) để nắm bắt ngữ cảnh tuyến tính.
- **Tối ưu hóa bài toán thực tiễn y tế:** Áp dụng chiến lược gán trọng số lớp (Class Weights) để giải quyết triệt để tình trạng mất cân bằng dữ liệu, đẩy mạnh chỉ số Recall lên mức $> 80\%$ nhằm ưu tiên bảo vệ an toàn cho bệnh nhân.
- **Kiểm soát độ tin cậy của AI:** Tích hợp kỹ thuật hiệu chuẩn nhiệt độ (*Temperature Scaling*) ở pha suy luận, giúp hệ thống đưa ra các mức độ tự tin (Confidence Score) khiêm tốn và đáng tin cậy hơn cho bác sĩ lâm sàng.

5.2. Hạn chế của hệ thống

Mặc dù đạt được những kết quả đánh giá khả quan trên tập dữ liệu DDI 2013, mô hình vẫn tồn tại một số giới hạn nhất định:

- **Hạn chế đối với cấu trúc câu phức tạp:** Khi đối mặt với các câu bệnh án quá dài (trên 100 từ vựng), chứa cấu trúc phủ định kép hoặc khoảng cách ngữ pháp giữa hai loại thuốc quá xa, luồng thông tin trong mạng GCN có hiện tượng suy giảm, dẫn đến nhận diện sai lệch.
- **Giới hạn của bộ biểu diễn từ vựng:** Việc sử dụng lớp Word Embedding cơ bản chưa đủ sức truyền tải và bao quát toàn bộ khối lượng kiến thức được lý, cơ chế sinh hóa chuyên sâu của các loại thuốc mới.

- **Sự đánh đổi về độ chuẩn xác (Precision):** Việc thiết lập hệ số phạt cao để ưu tiên Recall đã kéo theo sự gia tăng của các ca cảnh báo nhầm (False Positives), đòi hỏi bác sĩ vẫn phải tham gia kiểm chứng ở các trường hợp hệ thống có độ tự tin thấp.

5.3. Hướng phát triển tương lai

Để nâng cấp hệ thống đạt đến độ hoàn thiện cao nhất và sẵn sàng ứng dụng vào thực tế y tế, đề án đề xuất các định hướng phát triển như sau:

- **Tích hợp mô hình ngôn ngữ y sinh:** Thay thế lớp Embedding hiện tại bằng các mô hình học sâu tiên tiến như BioBERT hoặc SciBERT để làm giàu vốn từ vựng dược lý và thấu hiểu ngữ cảnh lâm sàng tốt hơn.
- **Áp dụng cơ chế Chú ý (Attention Mechanism):** Bổ sung các khối Attention vào mạng GCN nhằm giúp AI tự động hội tụ trọng số vào các từ khóa mang tính quyết định (ví dụ: "ức chế", "đối kháng", "làm tăng nguy cơ").
- **Phát triển ứng dụng Web (Web Application) và API:** Đóng gói mô hình lõi thành một giao diện web trực quan hoặc API độc lập. Sản phẩm cuối cùng sẽ hoạt động như một Hệ thống hỗ trợ quyết định lâm sàng (CDSS - Clinical Decision Support System), cho phép y bác sĩ nhập trực tiếp đơn thuốc hoặc đoạn bệnh án và nhận về cảnh báo tương tác thuốc theo thời gian thực.

TÀI LIỆU THAM KHẢO

- [1] Y. Luo, Y. Cheng, O. Uzuner, P. Szolovits, and J. Starren (2019). *Segment Graph Convolutional and Recurrent Neural Networks for Clinical Relation Extraction*. Journal of the American Medical Informatics Association, 26(3), 262–268.
<https://pmc.ncbi.nlm.nih.gov/articles/PMC6351971/>
- [2] I. Segura-Bedmar, P. Martínez, and C. Herrero-Zazo (2013). *DDI Extraction 2013 Corpus*. Drug-Drug Interaction Extraction Challenge Dataset.
<https://github.com/isegura/DDICorpus>
- [3] T. N. Kipf and M. Welling (2017). *Semi-Supervised Classification with Graph Convolutional Networks*. arXiv preprint arXiv:1609.02907.
<https://arxiv.org/abs/1609.02907>
- [4] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger (2017). *On Calibration of Modern Neural Networks*. Proceedings of the 34th International Conference on Machine Learning (ICML).
<https://arxiv.org/abs/1706.04599>
- [5] M. Honnibal and I. Montani (2017). *spaCy 2: Natural Language Understanding with Bloom Embeddings, Convolutional Neural Networks and Incremental Parsing*.
<https://spacy.io/>
- [6] A. Paszke et al. (2019). *PyTorch: An Imperative Style, High-Performance Deep Learning Library*. Advances in Neural Information Processing Systems (NeurIPS 32).
<https://pytorch.org/>